

# Portfolios robustos basados en máxima $L_q$ -verosimilitud penalizada

Felipe Osorio

<http://fosorios.mat.utfsm.cl>

Departamento de Matemática, UTFSM

*Laboratorio de Modelación I*

*Agosto 26, 2022*



El **estimador máximo  $Lq$ -verosímil (ML $q$ E)** de  $\theta$  es definido como aquél valor  $\hat{\theta}_q$  que maximiza la función (Ferrari y Yang, 2010)<sup>1</sup>:

$$L_q(\theta) = \sum_{i=1}^n l_q(f(\mathbf{y}_i; \theta)), \quad q > 0,$$

donde  $l_q(u)$  denota el **logaritmo deformado de orden  $q$** , cuya definición es dada por:

$$l_q(u) = \begin{cases} (u^{1-q} - 1)/(1 - q), & q \neq 1, \\ \log(u), & q = 1, \end{cases}$$

con  $f(\mathbf{y}_i; \theta)$  la función de densidad del modelo asumido para los datos.

### Observación:

Si  $q \rightarrow 1$ , entonces  $l_q(u) \rightarrow \log(u)$  y recuperamos el método de **estimación ML**.

---

<sup>1</sup>The Annals of Statistics **38**, 753-783.

El  $MLqE \hat{\theta}_q$  puede ser calculado resolviendo las ecuaciones de  $Lq$ -verosimilitud:

$$\Psi_n(\theta) = \sum_{i=1}^n \frac{\partial}{\partial \theta} l_q(f(\mathbf{y}_i; \theta)) = 0.$$

Es decir,  $\Psi(\theta)$  puede ser escrito como una función de estimación asociada a la solución de una verosimilitud ponderada

$$\Psi_n(\theta) = \sum_{i=1}^n \Psi_i(\theta) = \sum_{i=1}^n U_i(\theta) s_i(\theta),$$

donde  $U_i(\theta) = \{f(\mathbf{y}_i; \theta)\}^{1-q}$  y  $s_i(\theta) = \partial \log f(\mathbf{y}_i; \theta) / \partial \theta$ , corresponde a la función score para la  $i$ -ésima observación.

### Observación:

Cuando  $q$  es una constante fijada,  $\hat{\theta}_q$  pertenece a la clase de los  $M$ -estimadores.



Considere  $\mathbf{X} = (X_1, \dots, X_p)^\top$  vector denotando las rentabilidades de  $p$  activos medidos para un periodo de tiempo fijado, y suponga que siguen una distribución multivariada.

Podemos definir la **rentabilidad de un portfolio** mediante la combinación lineal  $\mathbf{X}^\top \boldsymbol{\beta}$ , siendo  $\boldsymbol{\beta} = (\beta_1, \dots, \beta_p)^\top \in \mathbb{R}^p$  un vector que representa como se realiza la distribución de los fondos entre los  $p$  activos.

### Objetivo:

Deseamos escoger  $\boldsymbol{\beta}$  tal que  $\mathbf{X}^\top \boldsymbol{\beta}$  sea lo más cercano posible a un **índice de rentabilidad de mercado**,  $Y$ .

---

<sup>2</sup>European Journal of Operational Research **250**, 251-261.



## Portfolios basados en estimación $MLq$ penalizada

Suponga  $(Y_1, \mathbf{x}_1), \dots, (Y_n, \mathbf{x}_n)$  pares de observaciones medidas en los tiempos  $i = 1, \dots, n$ . Se desea calcular  $\hat{\beta}_{q,\lambda}$  **maximizando la función objetivo**:

$$D_{q,\lambda}(\boldsymbol{\theta}) = \sum_{i=1}^n l_q \left\{ f \left( \frac{y_i - \mathbf{x}_i^\top \boldsymbol{\beta}}{\sigma} \right) \right\} + \sum_{j=1}^p l_q \{ h(\beta_j, \lambda) \},$$

donde  $\boldsymbol{\theta} = (\boldsymbol{\beta}^\top, \sigma)^\top$ , con  $\lambda > 0$  y  $q \leq 1$  constantes de regularización y distorsión fijas, mientras que  $f(\cdot)$  es función de densidad en la familia de posición y escala y  $h(\cdot, \cdot)$  representa una densidad simétrica con posición cero y escala  $\lambda$ .

### *Ejemplos de $h(\beta, \lambda)$ :*

Podemos considerar las siguientes densidades para la función de penalización,

► **Normal:**

$$h(\beta, \lambda) = (2\pi/\lambda)^{-1/2} \exp(-\lambda\beta^2).$$

► **Laplace:**

$$h(\beta, \lambda) = \frac{\lambda}{2} \exp(-\lambda|\beta|).$$



## Portfolios basados en estimación $MLq$ penalizada

La ecuación de estimación para  $\beta$ , digamos  $\partial D_{q,\lambda}(\theta)/\partial\beta = \mathbf{0}$ , adopta la forma

$$\sum_{i=1}^n U_i(\theta) \frac{\partial}{\partial\beta} \log f\left(\frac{y_i - \mathbf{x}_i^\top \beta}{\sigma}\right) + \dot{\mathbf{h}}_\lambda(\beta) = \mathbf{0},$$

donde  $\dot{\mathbf{h}}_\lambda(\beta)$  es un vector de derivadas cuyo  $j$ -ésimo elemento es dado por

$$W_j(\beta_j) \frac{\partial}{\partial\beta_j} \log h(\beta_j, \lambda), \quad j = 1, \dots, p,$$

y

$$U_i(\theta) = \left\{ f\left(\frac{y_i - \mathbf{x}_i^\top \beta}{\sigma}\right) \right\}^{1-q}, \quad W_i(\beta_j) = \{h(\beta_j, \lambda)\}^{1-q}.$$

### Observación:

Note que los “pesos”  $U_i(\theta)$  son dependientes de los datos y serán pequeños para observaciones atípicas, mientras que  $W_j(\beta_j)$  será pequeño si  $|\beta_j|$  es “grande”.



---

**Algoritmo 1:** Estimación doblemente re-ponderada (2RE)

---

**Entrada** : Datos  $\mathbf{X}$  y  $\mathbf{y}$

**Parámetros:** Constantes  $q \leq 1$  y  $\lambda > 0$ .

1 **begin**

2 Hacer  $s = 0$ , y calcular estimaciones iniciales  $\beta^{(s)}, \sigma^{(s)}$

3 **repeat**

4 Calcular  $\widehat{U}_i(\theta^{(s)})$  y  $\widehat{W}_j(\beta_j^{(s)})$  para  $i = 1, \dots, n$  y  $j = 1, \dots, p$

5 Obtener  $\widetilde{\beta}$  y  $\widetilde{\sigma}$ , maximizando:

$$\sum_{i=1}^n \widehat{U}_i \log f\left(\frac{y_i - \mathbf{x}_i^\top \beta}{\sigma}\right) + \sum_{j=1}^p \widehat{W}_j \log h(\beta_j, \lambda).$$

6 Actualizar  $\beta^{(s)}, \sigma^{(s)}$  resolviendo la ecuación:

$$f_q(z) = f_q(\widehat{z}^{(s)}), \quad z = (Y - \mathbf{x}^\top \beta)/\sigma,$$

donde  $f_q(z) = \{f(z)\}^q / \int \{f(z)\}^q dz$ .

7 **until** *alcanzar convergencia*

8 **return**  $\widehat{\beta}_{q,\lambda} = \widetilde{\beta}^{(s)}, \widehat{\sigma}_{q,\lambda} = \sigma^{(s)}$ .

9 **end**

---



Considere la transformación

$$f_q(\mathbf{x}; \boldsymbol{\theta}) = \frac{\{f(\mathbf{x}; \boldsymbol{\theta})\}^q}{\int_{\mathcal{X}} \{f(\mathbf{x}; \boldsymbol{\theta})\}^q d\mathbf{x}}.$$

La función  $f_q(\mathbf{x}; \boldsymbol{\theta})$  es conocida como **densidad distorsionada** (escort). El parámetro  $q$  provee un mecanismo para acentuar diferentes regiones de la densidad verdadera no transformada  $f(\mathbf{x}; \boldsymbol{\theta})$ .

### Observación:


En efecto, para:

- ▶  $q > 1$ , regiones con valores cuya densidad son cercanos a 0 son acentuados.
- ▶  $q < 1$ , regiones con valores lejanos desde 0 son enfatizados, es decir, **el rol de valores atípicos es reducido**.






## Ejemplo: Distribución normal estándar $N(0, 1)$



(a)  $q < 1$



(b)  $q > 1$

## Ejemplo: Distribución normal estándar $N(0, 1)$

Para la distribución  $N(0, 1)$ , tenemos<sup>3</sup>

$$\phi(z) = (2\pi)^{-1/2} \exp(-z^2/2), \quad \phi_q(z) = (2\pi/q)^{-1/2} \exp(-qz^2/2).$$

El **paso 6** del **Algoritmo 1** para la distribución  $N(0, 1)$ , lleva a la actualización

$$\beta^{(s)} = \tilde{\beta}, \quad \sigma^{(s)} = \tilde{\sigma}/\sqrt{q}.$$

Adicionalmente, para **asegurar la convergencia** del Algoritmo 1 es requerido que  $f_q(z)$  pertenezca a la misma familia que  $f(z)$ .

La motivación del paso 6 del Algoritmo 1 proviene de que, en general, el método de máxima  $Lq$ -verosimilitud, **no satisface**<sup>4</sup>

$$E_{\theta}\{\Psi_n(\theta)\} = \mathbf{0}.$$

La estrategia en el paso 6 es **sólo una manera de resolver este problema**.

---

<sup>3</sup> $\phi_q(z)$  es la densidad de una variable aleatoria  $N(0, q^{-1})$ .

<sup>4</sup>Es decir, resolver  $\Psi_n(\theta) = \mathbf{0}$  no lleva a estimadores Fisher-consistentes.



En Giuzio et al. (2016) se realiza una presentación detallada de:

- ▶ Algoritmo de estimación basado en portfolios normales.
- ▶ Algoritmo EM (Qin y Priebe, 2013)<sup>5</sup> para portfolios  $t$ -Student basados en la propiedad

$$Y_i | \tau_i \sim N(\mathbf{x}_i^\top \boldsymbol{\beta}, \sigma^2 / \tau_i), \quad \tau_i \sim \text{Gamma}\left(\frac{\nu}{2}, \frac{\nu}{2}\right),$$

para  $i = 1, \dots, n$ .

- ▶ Para la selección del parámetro de regularización, se considera

$$\text{SIC}_q = -2 \sum_{i=1}^n l_q \left\{ f\left( \frac{y_i - \mathbf{x}_i^\top \hat{\boldsymbol{\beta}}_{q,\lambda}}{\hat{\sigma}_{q,\lambda}} \right) \right\} + k \log n,$$

donde  $k \leq n$  denota el número de portfolios activos (es decir, el número de  $\beta$ 's distintos de cero). Además  $\text{SIC}_q \rightarrow \text{SIC}$  conforme  $q \rightarrow 1$ .

---

<sup>5</sup>Journal of the American Statistical Association **108**, 914-928



- ▶ Se desea implementar:
  - a) Estimación  $MLq$ -verosímil para **portfolios normales** y  $t$ -Student.
  - b) Selección del parámetro de regulación usando **criterios de información robustos** (Ronchetti, 1997)<sup>6</sup> o **validación cruzada generalizada ponderada** (O'Sullivan et al., 1986)<sup>7</sup>.
- ▶ Aplicar la metodología de Giuzio et al. (2016) a **datos del mercado de AFP's chileno**.
- ▶ Datos disponibles en **GitHub**: <https://github.com/faosorios/AFP>

---

<sup>6</sup>Statistica Sinica **7**, 327-338

<sup>7</sup>Journal of the American Statistical Association **81**, 96-103



# Referencias bibliográficas



Giuzio, M., Ferrari, D., Paterlini, S. (2016).

Sparse and robust normal and  $t$ - portfolios by penalized  $L_q$ -likelihood.  
*European Journal of Operational Research* **250**, 251-261.



Ferrari, D., Paterlini, S. (2009).

The maximum  $L_q$ -likelihood method: An application to extreme quantile estimation in finance.  
*Methodology and Computing in Applied Probability* **11**, 3-19.



Ferrari, D., Yang, Y. (2010).

Maximum  $L_q$ -likelihood estimation.  
*The Annals of Statistics* **38**, 753-783.



Qin, Y., Priebe, C.E. (2013).

Maximum  $L_q$ -likelihood estimation via the Expectation-Maximization algorithm: A robust estimation of mixture models.  
*Journal of the American Statistical Association* **108**, 914-928.



Ronchetti, E. (1997).

Robustness aspects of model choice.  
*Statistica Sinica* **7**, 327-338.

